

SENSOR-IA-L:

Sistema de Visió Avançada pel Monitoreig de Líquids Químics en la Galvanotècnia

Sergi Sanz Orellana

Resum—Resum del projecte, màxim 10 línies.

Paraules clau— Visió per Computador, Intel·ligència Artificial, Aprenentatge Profund, Xarxes Neuronals, Classificació de Imatges, Reconeixement de Anomalies, Planta Pilot, Galvanotècnia, Càmera, Algorismes de Predicció

Abstract—Versió en anglès del resum.

Index Terms— Computer Vision, Artificial Intelligence, Deep Learning, Neural Networks, Image Classification, Anomaly Detection, Pilot Plant, Electroplating, Camera, Prediction Algorithms

1 INTRODUCCIÓ - CONTEXT DEL TREBALL

En el context en el que es troba la creació d'aquest treball de fi de grau d'enginyeria informàtica de la universitat autònoma de Barcelona, és el de les indústries químiques en col·laboració amb l'empresa Chemplate Materials. Aquesta empresa és especialitzada en la distribució i manufactura de productes químics semielaborats per a aplicacions en sectors com la galvanotècnia i l'electrònica. La supervisió i el manteniment de la qualitat dels processos de producció són un dels factors crítics per a garantir l'eficàcia, la seguretat i la fiabilitat de les operacions.

Aquest projecte es troba en el marc d'un prototip d'una línia de cubetes on hi ha certes cubetes que tenen líquids químics que es volen monitoritzar amb tècniques de visió per computador i deep learning (veure Fig. 1).



Fig. 1. Planta pilot de Chemplate ubicada en nau externa.

- E-mail de contacte: 1599507@uab.cat
- Menció realitzada: Computació
- Treball tutoritzat per: J. Vazquez Corral (Ciències Computació)
- Curs 2023/24

Les plantes pilot de Chemplate, que serveixen com a entorns crucials per al desenvolupament i la prova de tractaments químics innovadors, requereixen una supervisió contínua i precisa per a garantir el funcionament òptim dels processos. En un d'aquests processos de recobriment de peces en la galvanotècnia, es vol desenvolupar un sistema avançat de monitoratge i detecció d'anomalies amb l'ús de varies càmeres.

Amb el context clar, crearem el disseny i la implementació d'un sistema de visió avançat que utilitzi una combinació de càmeres de alta definició i plataformes computacionals.

Ha de ser capaç de detectar i classificar canvis inesperats en aquests líquids, canvis com: la presència d'escuma, canvis de color o la formació de fum, entre d'altres. Amb l'objectiu de prevenir la degradació dels productes químics i garantir la seguretat del procés, ja que aquests poden indicar problemes en el procés de producció que afecten la seguretat i eficàcia de la planta.

Aquesta tasca es tot un repte de IoT, requereix una combinació de tecnologies d'adquisició d'imatges, processament d'imatges, algorismes de deep learning per a la classificació, juntament amb el disseny d'una interfície d'usuari intuïtiva per a la supervisió, avís i control del sistema.

1.1 Estructura del document

Aquest projecte, en format d'article, segueix la següent estructura: comença per la introducció, on es proporciona el context del treball, els objectius i la planificació. La secció següent, "Estat del Art", s'adreça als fonaments teòrics, amb apartats que aborden algorismes de classificació d'imatges, xarxes neuronals convolucionals amb un enfocament detallat, l'èxit de les CNNs i els vision transformers.

La metodologia és presentada en la tercera secció, seguida del desenvolupament, els resultats obtinguts, i finalment, les conclusions. Els agraïments, bibliografia i un apèndix completen aquesta estructura, proporcionant una visió global i detallada del projecte.

1.2 Objectius

Per a du a terme amb èxit aquesta implementació és important definir uns objectius clars i factibles, els podem subdividir en 5 objectius específics:

- A. Aprendre, familiaritzar-me sobre el camp de la visió per computador, també sobre el deep learning i fer un estudi del art de la classificació multi classe d'imatges.
- B. Desenvolupar un sistema de captura d'imatges utilitzant tres càmeres connectades a varies plataformes computacionals per monitorar les cubetes de líquids químics.

- C. Creació de un ampli dataset amb tots el casos possibles de anomalies i classificar les imatges capturades en quatre categories: sense problemes, canvi de color, nivell alt d'escuma i nivell alt de vapor.
- D. Creació i implementació d'algoritmes de classificació d'imatges per a la detecció d'anomalies, per mitjà de tècniques d'aprenentatge profund.
- E. Desenvolupar una interfície d'usuari intuïtiva per visualitzar l'estat del sistema, les imatges capturades i els resultats de la classificació. Per exemple pàgina web.

1.3 Planificació

La planificació es crucial ja que ens permet crear un camí a traçar per assolir els objectius.



2 ESTAT DEL ART

El camp de la classificació d'imatges, es actualment un dels camps més importants de la visió per computador. Però abans d'aprofundir en el concepte de classificació d'imatges, caldria reflexionar sobre la següent qüestió: Per què és crucial la classificació d'imatges?

Ens trobem immersos en l'era de la informació. Amb l'expansió de l'Internet de les Coses (IoT) i l'augment de l'ús de la Intel·ligència Artificial (IA), el món genera una immensa quantitat de dades. Aquestes dades poden prendre formes diferents però les imatges, representen una part fonamental en la generació d'aquesta informació a escala global. En essència, és la tasca d'assignar una etiqueta a una imatge a partir de un conjunt predefinit de categories.

Els models de deep learning han demostrat ser més precisos i efectius que els mètodes tradicionals de classificació d'imatges. Gràcies a la capacitat de l'aprenentatge automàtic per aprendre característiques d'un conjunt de dades, els models poden identificar patrons i característiques per classificar les imatges.

La classificació d'imatges amb l'ajuda de la IA és un àmbit molt actiu de recerca i desenvolupament, i s'està utilitzant en diverses aplicacions. Aquest ampli camp abasta una gran varietat de tipus d'imatges, des de simples fotografies fins a imatges mèdiques complexes.

Pot haver-hi confusió al voltant dels termes "xarxes neuronals" i "deep learning", ja que sovint s'utilitzen indistintament. L'aprenentatge profund (deep learning) fa referència específicament a l'ús de xarxes neuronals amb múltiples capes, d'aquí el terme "profunditat" per denotar la profunditat de l'arquitectura de la xarxa.

El deep learning es una tècnica de Machine learning que utilitza xarxes neuronals profundes amb moltes capes per fer prediccions. D'aquesta manera s'aconsegueix un aprenentatge de extrem a extrem, és a dir, les imatges son les entrades i tant les característiques com la classificació s'aprenen directament a partir de les imatges d'entrada.

Tot aprenentatge profund implica xarxes neuronals, però no totes les xarxes neuronals són models d'aprenentatge profund. Una xarxa neuronal amb només unes poques capes normalment no es consideraria un model d'aprenentatge profund, mentre que una xarxa neuronal amb múltiples capes ocultes s'inclouria en la categoria d'aprenentatge profund [1].

2.1 Algorismes de Classificació d'Imatges:

Els algorismes utilitzats en la classificació d'imatges són fonamentals per a l'èxit del procés. Els 3 més comuns són:

2.1.1 Màquines de Vectors de Suport (SVM):

Els SVM són àmpliament utilitzats en la classificació d'imatges degut a la seva capacitat per trobar el hiperplà que millor separa les classes en l'espai de característiques. Utilitzen vectors de suport per definir aquest hiperplà, que maximitza el marge entre les classes. Els SVM poden ser eficaços especialment en conjunts de dades amb característiques linealment separables.

2.1.2 Arbres de Decisió:

Aquests algorismes utilitzen una estructura d'arbre per classificar objectes en diferents categories. Cada node de l'arbre representa una característica de la imatge, i les branques representen les possibles sortides basades en aquesta característica. Els arbres de decisió són fàcils d'interpretar i poden manejar tant dades numèriques com categòriques.

2.1.3 Xarxes Neuronals Convolucionals (CNN):

Les xarxes neuronals són un model computacional inspirat en l'estructura i funció del cervell humà respecte a les neurones. Consisteixen en nodes interconnectats organitzats en capes. Aquestes xarxes es poden utilitzar per a diverses tasques, incloent classificació, regressió, reconeixement de patrons i més.

Són particularment efectives per al processament d'imatges degut a la seva capacitat per extreure característiques rellevants d'elles. Utilitzen capes convolucionals que apliquen filtres a la imatge per detectar patrons com a marges, textures i formes. Després, aquestes característiques passen a través de capes de pooling per reduir la dimensionalitat i finalment es connecten a capes denses per a la classificació.

Sorgeix una qüestió interessant entre aquests dos últims algorismes: una xarxa neuronal realment és un arbre de decisió molt extens?

Doncs bé, aquesta problemàtica es molt ben estudiada en el paper "Neural Networks are Decision Trees" de Caglar Aytekin [2], on s'estudia en profunditat els dos algorismes i s'acaba concluint que realment les xarxes neuronals es poden representar equivalentment com a arbres de decisió, on aquesta representació és d'equivalència i no una aproximació.

2.2 Xarxes Neuronals Convolucionals en detall:

2.2.1 Xarxes neuronals convolucionals:

Les xarxes neuronals convolucionals, també conegudes com a CNN (Convolutional Neural Networks), són especialment adequades per a tasques de processament d'imatges. Utilitzen capes de convolució per extreure característiques visuals importants, com ara vores, formes i textures, la qual cosa les fa ideals per a la classificació multi classe d'imatges, detecció d'objectes i seguiment de moviment.




Fig 2. Esquema visual de una CNN. Font Matlab [8].

2.3 Èxits de Xarxes neuronals convolucionals:

En l'última dècada, el desenvolupament d'arquitectures de xarxes neuronals convolucionals ha estat fonamental per a l'avanç en tasques de visió per computador, particularment en la classificació d'imatges. Algunes de les arquitectures més influents en aquest camp han sigut: VGG16, ResNet i Inception. Creades per les universitats més importants o empreses tecnològiques més grans del món.




Fig. X. CNNs per a la classificació de imatges. Font Matlab [8].

2.3.1 Model VGG:

VGG, que representa al Visual Geometry model, és un model proposat per investigadors de la Universitat d'Oxford el 2014 per a tasques de classificació d'imatges mitjançant xarxes neuronals convolucionals [X]. VGG va destacar la importància de la profunditat en les CNNs, demostrant que una xarxa profunda amb filtres 3x3 pot aprendre característiques complexes. Abans de VGG, les CNNs solien tenir menys capes i filtres més grans, mentre que VGG va mostrar que una arquitectura senzilla amb filtres 3x3 podia rivalitzar amb models més complexos [3].

És una arquitectura influent en el desenvolupament de CNNs per a visió per computador, destacant la importància de la profunditat, els filtres petits i l'estructura en capes per a l'aprenentatge de característiques complexes en imatges. Tot i que VGG va aconseguir resultats destacats en classificació d'imatges, la seva profunditat i cost computacional són desafiaments importants.

2.3.2 Model ResNet:

ResNet, abreujament de Xarxa Residual (Residual Network), va ser proposat per investigadors de Microsoft el 2015 per abordar el problema de la desaparició del gradient en xarxes neuronals molt profundes [4]. Aquest problema sorgeix en el entrenament de xarxes profundes, on els gradients disminueixen exponencialment mentre es propaguen cap enrere a través de moltes capes durant l'entrenament, dificultant que les capes primeres aprenguin de manera efectiva.

Les arquitectures de ResNet consisteixen en apilar múltiples blocs residuals, permetent la construcció de xarxes molt profundes amb més de 100 capes. ResNet va introduir el concepte d'aprenentatge residual utilitzant connexions de salt per abordar el problema de la desaparició del gradient en xarxes neuronals profundes, conduint a un entrenament més ràpid i fàcil de xarxes molt profundes i aconseguint resultats d'última generació en tasques com la classificació d'imatges.

2.3.3 Inception:

Desenvolupada per Google Research al 2015 [5], Inception V3 és una evolució de les arquitectures Inception anteriors. Utilitza mòduls d'Inception, que consisteixen en conjunts de convolucions de diferents mides i pooling, concatenant les sortides. Es combinen múltiples camins paral·lels de convolucions i pooling per extreure característiques a diferents escales. Aconsegueix un equilibri entre rendiment i eficiència computacional, sent capaç de manejar imatges d'alta resolució de manera efectiva.

En resum, les arquitectures VGG16, ResNet i Inception V3 han estat crucials en l'avanç de la visió per computadora. Cadascuna d'aquestes arquitectures té les seves pròpies característiques distintives i desafiaments, i la seva elecció depèn del problema específic que s'estigui abordant i les restriccions computacionals disponibles.




Fig. X. Estat del art dels models per a la classificació de imatges basat del dataset famós Imagenet. Font PapersWithCode [6].

En resum, les xarxes neuronals convolucionals són una eina fonamental en la intel·ligència artificial i l'aprenentatge automàtic. Comprendre els diferents tipus de xarxes neuronals i les seves aplicacions és essencial per aprofitar al màxim el seu potencial en una àmplia varietat de problemes.

De les xarxes neuronals basades en les CNNs van evolucionar a una nova tecnologia presentada en el 2021 que detallaré a continuació.

2.4 Vision Transformer (ViT):

Introduït per Dosovitskiy et al. el 2021 [7], els Vision Transformers (ViTs), són una nova arquitectura de xarxa neuronal que està revolucionant el camp de la visió per computador. A diferència dels models convolucionals, que han dominat la visió per computador durant anys, els ViTs fan servir transformadors, una arquitectura inicialment dissenyada per a tasques de processament de llenguatge natural, aquesta són la base dels models de intel·ligència artificial com ara ChatGPT.

Els Vision Transformers funcionen segmentant la imatge d'entrada en petits fragments, que són aplanats i introduïts en una arquitectura de transformador. En lloc d'utilitzar capes convolucionals, els transformadors processen aquests fragments utilitzant matrius d'atenció per aprendre les relacions entre els píxels. Aquest enfocament permet als ViTs capturar relacions de llarga distància en les imatges sense dependre de les operacions locals de les convolucions.

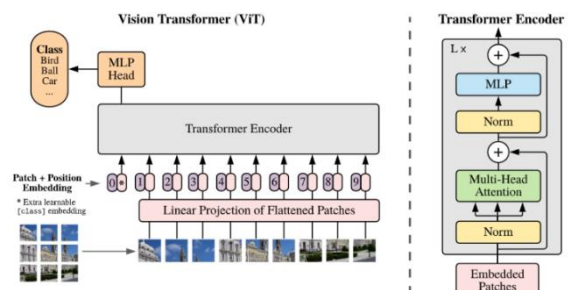


Fig. X. ViT per a la classificació de imatges. Font paper: An image is worth 16x16 words [7].

Tradicionalment, les CNNs han estat l'arquitectura preferida per a diverses tasques de visió per computador, incloent-hi la classificació d'imatges, la detecció d'objectes i la segmentació. No obstant això, l'arquitectura Transformer, va demostrar un rendiment incomparable a través de l'ús de mecanismes d'autoatenció.

Però tot i així, en un dels articles més importants sobre aquest tema anomenat "An Image is Worth 16x16 Words: Transformers for Image Recognition, 2021" es diu:

"In computer vision, however, convolutional architectures remain dominant..."

Això es dit ja que s'ha pogut comprovar que els ViT son millors que les CNNs a partir de les 100 milions de imatges de entrenament i pel moment no es una millora molt significativa, per al cost computacional que impliquen. En resum, els Vision Transformers estan canviant la manera en què abordem la visió per computador, proporcionant una alternativa innovadora i prometedora a les CNNs.

Amb tot aquest estudi del art clar, considero que la metodologia més adient per portar a terme aquest projecte és la creació d'una red neuronal convolucional bàsica i adient per a que funcioni bé en el problema a resoldre i per una altra part seria interessant comparar-la amb adaptacions d'altres xarxes neuronals aplicant l'ús de la metodologia Transfer Learning [10]. Una vegada fet això, escollir el millor resultat per a la aplicació del projecte.

3 METODOLOGIA

En aquesta part del treball es posaran en pràctica alguns dels coneixements desenvolupats anteriorment. L'objectiu és crear un classificador d'imatges multi classe que identifiqi amb una alta precisió en quin estat es troba de 4 categories possibles:

- 1) Sense problemes
- 2) Canvi de color
- 3) Nivell alt d'escuma
- 4) Nivell alt de vapor.

Per a du a terme això s'utilitzaran conceptes de deep learning per realitzar el codi en python amb la llibreria Keras i també desde Matlab on s'entrenarà el model d'aquest classificador i es compararan entre les xarxes neuronals ja preentrenades.

3.1 Dataset:

Per poder crear un bon classificador, és molt important el conjunt de dades o dataset. Com més equilibrat sigui aquest conjunt de dades i més representatiu sigui, més precisió s'obindrà. Es dividirà entre un 70% del data set com a traint, un 20% com a validació i un 10% com a test.

3.1.1 Preprocessament de les dades:

El preprocessament de dades és essencial per garantir que les dades estiguin en el format adequat i siguin de qualitat abans d'entrenar el model. Aquí es detallen algunes tècniques comunes:

- **Redimensionament d'Imatges:** Ajustar totes les imatges a una mida comuna facilita el processament i redueix la variabilitat en el conjunt de dades, es sol utilitzar un ajustament quadrat de 224x224.
- **Normalització d'Imatges:** Assegurar que els valors dels píxels estiguin en un rang específic, com 0 a 1, ajuda a estandaritzar les dades i facilita el procés d'entrenament, el mateix amb el color, si una imatge es a escala de grisos s'ha de transformar a imatges RGB amb els 3 canals de color.
- **Augment de Dades:** Generar noves imatges a partir de les existents mitjançant transformacions com rotacions, desplaçaments o canvis en el contrast augmenta la diversitat del conjunt de dades i ajuda a prevenir el overfitting.

3.1.2 Entrenament del model:

L'entrenament del model implica alimentar-lo amb dades etiquetades i ajustar els seus paràmetres perquè pugui realitzar prediccions precises sobre noves imatges. Aquest procés generalment implica iteracions d'ajust dels paràmetres del model fins que aconsegueixi un nivell satisfactori de precisió.

3.1.3 Avaluació del rendiment:

L'avaluació del rendiment del model es realitza utilitzant mètriques com l'acurracy i el Loss. Aquestes mètriques permeten comprendre com de bé està realitzant les classificacions el model i quantes classificacions correctes realitza en relació amb les classificacions incorrectes de manera general.

3.1.4 Ajust del model:

L'ajust del model implica realitzar modificacions en els paràmetres del mateix per millorar el seu rendiment. Això pot incloure l'optimització dels hiperparàmetres, l'augment de la mida del conjunt d'entrenament o l'aplicació de tècniques de preprocessament addicionals per millorar la qualitat de les dades.

3.1.5 Transfer Learning:

És molt pràctic començar amb una xarxa preentrenada, com ara GoogLeNet. Però manca de flexibilitat en quant a la forma en què funciona la xarxa, i probablement no resoldrà el problema concret que desitja resoldre. Podeu crear i entrenar una xarxa des de zero, començant només amb l'arquitectura de la xarxa i pesos aleatoris. Però aconseguir bons resultats requereix molt d'esforç: (1) coneixements i experiència en arquitectura de xarxes (2) una gran

quantitat de dades d'entrenament i (3) molt temps de càlcul. La transferència d'aprenentatge és una solució eficient per a molts problemes. La formació requereix algunes dades i temps de càlcul, però és més ràpida que començar de zero, i el resultat és una xarxa adaptada específicament al seu problema.




Fig X. Gràfica esforç versus flexibilitat. Font Matlab [8].

El transfer learning és una tècnica que aprofita models preentrenats en grans conjunts de dades i els adapta per classificar imatges en un domini específic. Això s'aconsegueix reemplaçant la capa de sortida del model preentrenat i reentrenant-lo amb dades específiques del nou domini. Farem la comparació entre els resultats de la xarxa neuronal creada desde zero i les xarxes VGG-19, Resnet-50 i Xception.

Amb l'ajuda de Matlab podrem fer això de manera molt fiable, ja que te carregats en el programa les xarxes neuronals més famoses i amb la seva eina Deep Network Designer podem modificar les últimes capes per a que s'ajusti al nostre dataset. També ho farem amb python utilitzant els mateixos models importats de la llibreria Keras.io i Tensorflow (veure Fig. X).




Fig. X. Explicació visual de Transfer Learning. Font MATLAB [8].

Available models

Model	Size (MB)	Top-1 Accuracy	Top-5 Accuracy	Parameters	Depth	Time (ms) per inference step (CPU)	Time (ms) per inference step (GPU)
Xception	88	79.0%	94.5%	22.9M	81	109.4	8.1
VGG16	528	71.3%	90.1%	138.4M	16	69.5	4.2
VGG19	549	71.3%	90.0%	143.7M	19	84.8	4.4
ResNet50	98	74.9%	92.1%	25.6M	107	58.2	4.6

Fig. X. Els 4 millors models desde Tensorflow. Font Keras [10].

3.1.6 Proves exhaustives i comparació de resultats

Realitzar proves exhaustives implica avaluar el rendiment del model en diferents escenaris i condicions per garantir la seva eficàcia i robustesa. Això pot incloure la variació en la il·luminació, l'angle de visió, la mida de la imatge, entre altres factors, per assegurar-se que el model pugui generalitzar bé a situacions reals en la planta pilot de Chemplate.

3.1.7 Monitoreig i avis

Quan això estigui funcionant a la perfecció el que es farà és un sistema automàtic de notificacions, avisos i monitoreig. On al responsable i al supervisor de la planta sigui avisat quan algun dels problemes succeeixi.

4 DESENVOLUPAMENT

El primer pas és la elecció de la càmera, després de haver fet un estudi sobre les possibilitats que hi ha en el mercat i ajustant-me al pressupost de l'empresa, m'he decantat per la càmera ELP Pro USB4k, ideal per projectes de visió per computador. Degut a que te connectivitat per USB i és una de les millors càmeres industrials del mercat, destacar la seva qualitat de imatge i de vídeo, tan de resolució com de color i el seu zoom digital de fins 5x indispensable per enquadrar la imatge al nostre gust. Com hem de monitoritzar tres cubetes, hem comprat tres.



Fig X. X. Càmera ELP Pro USB4k.

Aquestes càmeres per si soles no poden fer res, necessiten d'un ordinador. La manera més adequada es connectar-les a unes Raspberrys Pi Zero 2 [11]. Es tracten d'un petit ordinador de placa única que està dissenyat per ser extremadament compacte i assequible, però encara ofereix un bon rendiment per a una varietat de projectes d'electrònica, informàtica i programació. Algunes de les seves característiques inclouen un processador ARM de 4 nuclis, 512 MB de RAM, connectivitat sense fils Wi-Fi i Bluetooth, ports USB, GPIO (General Purpose Input/Output) per connectar perifèrics i expansions, i compatibilitat amb una àmplia gamma de sistemes operatius, incloent-hi diverses distribucions de Linux. També hem comprat 3 per a que cada càmera funcioni de manera independent.



Fig X. X. Raspberry Pi Zero 2W [11].

El següent pas és poder connectar-nos a les càmeres remotament per mitjà de les Raspberry Pi Zero 2. Per a poder accedir remotament he utilitzat la plataforma VNC Viewer [12] que permet connectar-se a una IP concreta, però amb la restricció de què l'ordinador i la Raspberry (en aquest cas) han d'estar connectades a la mateixa xarxa Wi-Fi. Com la línia es troba en una altra ubicació que les oficines, l'aplicació no permet poder accedir-hi remotament. Per solucionar aquest problema, el que he fet és crear una VPN per a cada Raspberry i pel meu ordinador amb l'aplicació DrayTek [13].

Gràcies a això i a un petit script.sh que s'executarà automàticament quan una Raspberry estigui connectada a el

corrent, es connectarà al Wi-Fi de la nau on està la línia i directament encendrà la VPN i així podrem accedir remotament des de qualsevol lloc a les càmeres.

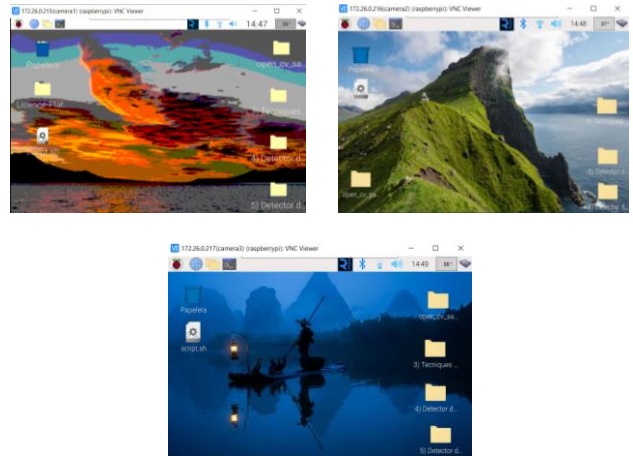


Fig X. X. Les 3 Raspberry Pi Zero 2, controlades remotament amb VNC Viewer [12].




Fig X. X. Esquema de la connectivitat del sistema.

Una vegada tenim resolta la connectivitat remota de les càmeres i les Raspberry amb l'ordinador personal el següent pas es considerar l'estructura on hi estaran les càmeres fixes per a demanar la seva creació a una empresa externa capaç de fer-la:

- L'estructura ha de ser independent a la línia pilot (es recolzarà directament al terra).
- L'estructura haurà de tenir una barra regulable en alçada entre 1,70 i 2,20cm.
- L'estructura ha de permetre la fixació de càmeres en la seva estructura. Ha de ser robusta i segura.
- No es contempla cap tipus de sistema per desplaçament de les càmeres.



Fig. X. Estructura muntada en la planta pilot de Chemplate.

Amb aquesta estructura que passarà per sobre de la línia de les cubetes quedaran fixades les tres càmeres, ens interessa analitzar amb visió per computador la cubeta 1, 3 i 5. La primera apuntant a la cubeta 1, on hi ha líquids de desengreix químic electrolític, i la segona apuntant a la cubeta 3, on hi ha líquid nítric de decapat per a peces de alumini i la tercera en la cubeta 5, on hi ha aigua desionitzada. Les cubetes 6,7,8 son igual que la cubeta 1.

El flux d'una peça que passa per la línia és:

- ➔ Cubeta 1 de desengreix
- ➔ Cubeta 2 aigua de red
- ➔ Cubeta 3 decapat per a peces d'alumini.
- ➔ Cubeta 4 aigua de red (ducha)
- ➔ Cubeta 5 de aigua desionitzada.



Fig. X. Càmera i Raspberry col·locades a l'estructura construïda.

Una vegada aquests passos realitzats, càmeres col·locades i connectades a les Raspberry, es el moment de fer experiments i crear el nostre dataset. Per mitjà d'un fitxer creat amb Python executarem el programa per fer la captura de imatges i aquestes imatges es guardaran en carpetes segons el dia i la hora exacta de la realització de la fotografia.

És important tenir una bona quantitat de fotografies, però sobretot moltes imatges diferents, on es vegin clars els events que poden ocórrer. Per lo tant hem de provocar aquests canvis que poden succeir per tenir una bon ventall de imatges i així poder crear un bon model entrenant-lo amb aquestes imatges.

La planificació dels experiments per la captura de dades durant el mes de abril i maig es la següent:

- ➔ Dimecres 17 de abril, instal·lació càmeres i Raspberry ben connectades a la estructura construïda.
- ➔ Els experiments començaran a partir de la setmana del 22 d'abril. (s'han de concretar).

Les imatges es guardaran dins de cada Raspberry que tenen una capacitat de 128GB, i remotament es recolliran les imatges realitzades, per pre-processarles i crear-ne una xarxa neuronal capaç de aconseguir la classificació desitjada.

Primeres proves/imatges a la cubeta 1 (març):



Estat inicial



Agitació activada



Alt nivell de escuma



Baix nivell de escuma

5 RESULTATS

.....

Visitat el: 19/04/24

- [13] DrayTek. (s.f.). DrayTek Smart VPN Client. Recuperat de <https://www.draytek.com/products/smart-vpn-client/> Visitat el: 19/04/24

6 CONCLUSIONS

.....

7 AGRAÏMENTS

.....

8 BIBLIOGRAFIA I FONTS D'INFORMACIÓ

- [1] IBM. (s.f.). Neural Networks. Recuperat de <https://www.ibm.com/topics/neural-networks> Visitat el: 19/04/24
- [2] Aytakin, C. (2022). Neural networks are decision trees. arXiv preprint arXiv:2210.05189.
- [3] Simonyan, K., & Zisserman, A. (2014). Very deep convolutional networks for large-scale image recognition. arXiv preprint arXiv:1409.1556.
- [4] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 770-778).
- [5] Szegedy, C., Vanhoucke, V., Ioffe, S., Shlens, J., & Wojna, Z. (2016). Rethinking the inception architecture for computer vision. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 2818-2826).
- [6] Papers With Code. (s.f.). Image Classification on ImageNet. Recuperado de <https://paperswithcode.com/sota/image-classification-on-imagenet> Visitat el: 19/04/24
- [7] Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., ... & Houlsby, N. (2020). An image is worth 16x16 words: Transformers for image recognition at scale. arXiv preprint arXiv:2010.11929.
- [8] MATLAB. (2010). version 7.10.0 (R2023b). Natick, Massachusetts: The MathWorks Inc.
- [9] Python Software Foundation. (2020). Python 3.9. Recuperat de <https://www.python.org/downloads/release/python-390/> Visitat el: 19/04/24
- [10] Gulli, A., & Pal, S. (2017). Deep learning with Keras. Packt Publishing Ltd.
- [11] Raspberry Pi Foundation. (s.f.). Raspberry Pi Zero 2 W. Recuperado de <https://www.raspberrypi.com/software/> Visitat el: 19/04/24
- [12] RealVNC Ltd. (2024). VNC Viewer (Versió 6.21.118). <https://www.realvnc.com/en/connect/download/viewer/>

9 APÈNDIX

A1. SECCIÓ D'APÈNDIX

.....
.....
.....
.....

A2. SECCIÓ D'APÈNDIX

.....
.....
.....
.....